Clasificación de Imágenes Médicas con CNNs Jason Morrill, John Morrill

Jason Morrill John Morrill

1. Introducción

Desde la invención de los rayos X en 1895, la interpretación de imágenes médicas ha sido un desafío en constante evolución. Al interpretar imágenes médicas, los médicos no diagnostican la afección correcta en un 12,5% a +3% de los casos [2]. Dado que los procedimientos para tumores cerebrales son invasivos y costosos, es vital interpretar las imágenes cerebrales con precisión. Durante décadas, el aprendizaje automático ha mejorado la interpretación de imágenes médicas [1]. Actualmente, existen varios métodos avanzados de IA para imágenes médicas, y una red neuronal convolucional (CNN) de la misma empresa produjo una medición de precisión del 96% en resonancias magnéticas (Khan et al., 2022).

El propósito de este modelo de CNN es clasificar con precisión las imágenes extraídas de resonancias magnéticas en una de cuatro categorías. Esta herramienta de IA complementará el diagnóstico del médico mediante la preselección de imágenes o como una "segunda opinión". Los resultados obtenidos por este modelo son superiores a los de un médico promedio, y esta revisión adicional mejorará los resultados del tratamiento del cáncer cerebral.

2. Metodología

El método CNN consta de 5 pasos: preparación de datos, definición del modelo, entrenamiento del modelo, evaluación y ajustes posteriores. Los datos, provenientes de Kagglehub, consisten en 7023 resonancias magnéticas cerebrales divididas en 4 subcarpetas de tamaño similar y etiquetadas con 4 tipos diferentes de resultados de resonancia magnética cerebral: glioma, meningioma, hipófisis y sano.

La preparación de datos permite a las computadoras comparar imágenes. Para comenzar, cada imagen se etiqueta con una de las cuatro clases: glioma, meningioma, hipófisis y sano. A continuación, se redimensionan las imágenes para garantizar que mantengan la misma forma y tamaño. A continuación, las trayectorias de las imágenes se convierten en matrices para que la computadora y las redes neuronales puedan distinguirlas. El último paso del preprocesamiento consiste en dividir las matrices en grupos: 60 % para entrenamiento, 20 % para pruebas y 20 % para datos de validación.

Para la selección del modelo, se utilizó un modelo CNN, ya que captura características locales mediante convoluciones, lo cual es muy adecuado para la interpretación de imágenes. Se ha demostrado que las redes neuronales son tan eficaces como los médicos para detectar el melanoma[1].

Para el entrenamiento y las pruebas, el modelo CNN cuenta con ocho capas: entrada y salida, dos capas de agrupamiento, dos capas convolucionales, tres capas densas y una capa de salida. El modelo utiliza entropía cruzada categórica para la función de pérdida, activación ReLU para las capas ocultas y activación softmax para la capa de salida, con un total de 6 millones de parámetros. Se establecieron 10 épocas y 64 tamaños de lote. La arquitectura de la CNN se describe a continuación.

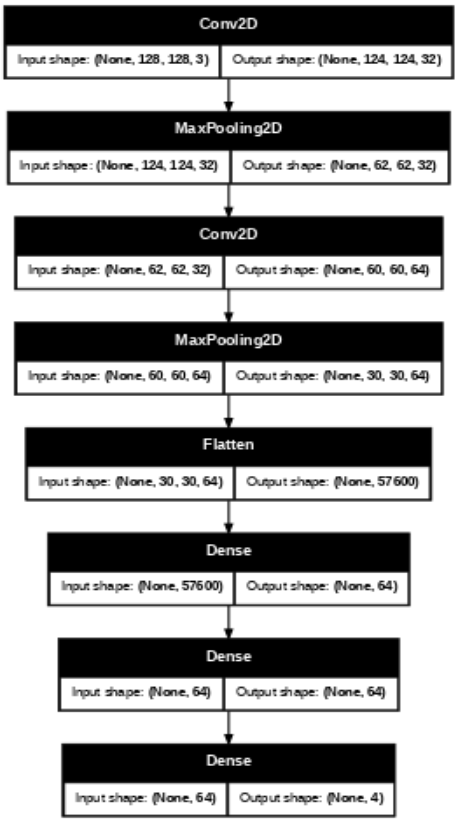


Figura 2.1: El gráfico anterior muestra las 8 capas de

procesamiento de la CNN. El procesamiento comienza en una matriz de 128x128 y disminuye en cada capa hasta alcanzar una predicción de categoría.

Para lograr una alta precisión y un menor consumo de energía, los hiperparámetros para las épocas se establecieron en 10. El tamaño del lote se estableció en 64, lo que proporciona un buen equilibrio entre precisión y velocidad, y evita el sobreajuste. Una tasa de aprendizaje del optimizador Adam de 0,001 proporcionó los resultados de entrenamiento óptimos. Se probaron otros hiperparámetros, como una mayor tasa de aprendizaje, un optimizador SGD, más épocas y un tamaño del lote menor, pero no se utilizaron porque no aportaban valor.

Para las pruebas de datos, las métricas utilizadas fueron la precisión y la puntuación f1. Como medida adicional, se realizó un análisis cualitativo para garantizar la precisión de los resultados. Se incluye una comparación visual de las imágenes con la clase predicha y la real.

3. Resultados

Resultados cualitativos: En segundos, el modelo interpretará las imágenes y determinará si el paciente tiene uno de los tres tipos de cáncer o si su cerebro está sano. Puede ser operado por personal con poca formación médica, ofreciendo mejores resultados generales que un médico convencional. Este modelo CNN está bien entrenado y funcionará de forma constante sin distracciones humanas.

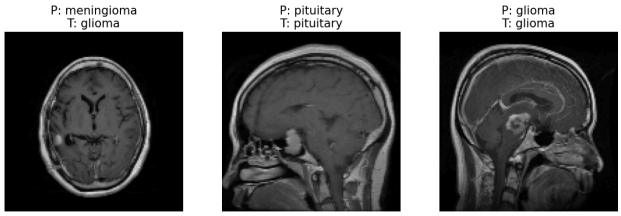


Figura 3.1: Visualización de diferentes exploraciones cerebrales. La primera muestra una predicción incorrecta y las dos últimas, correctas.

Resultados cuantitativos:

clase	Precisión	Recall	F1_score
Glioma	0.91	0.94	0.93
Healthy	0.97	0.98	0.97
Meningioma	0.87	0.89	0.88
Pituitary	0.99	0.94	0.96
Promedio	0.935	0.9375	0.935

Tabla 3.1: Resultados de cada una de las métricas principales (precisión, recuperación, puntuación F1) del modelo, junto con el promedio.

Los hiperparámetros evaluados tuvieron un excelente rendimiento: el optimizador SGD solo obtuvo una precisión del 83%, y el optimizador Adam, con una tasa de aprendizaje de 0,01, solo obtuvo una precisión del 73%.

4. Discusión

El modelo ilustra la utilidad y el potencial futuro del uso de CNN para la interpretación de imágenes médicas. El estudio utilizó 7023 imágenes para una CNN de 8 capas con 10 épocas, lo que produjo un resultado general del 93,8 %. En comparación, este modelo consume mucha menos energía computacional que otro modelo de CNN con 23 capas que categorizó exploraciones cerebrales con un resultado del 96 %. Este resultado del 94 % es de gran valor tanto para médicos como para pacientes. Para los médicos, la precisión brinda gran confianza y puede ser procesada rápidamente por un asistente con poca experiencia. El resultado de alta precisión para "sin cáncer" es un gran beneficio para el paciente, ya que evita tratamientos innecesarios. Los robustos resultados de este modelo ofrecen la posibilidad de utilizar CNN en otros tipos de imágenes médicas.

Existen limitaciones en el uso de IA para la clasificación de imágenes. La primera limitación de este modelo es que su precisión es del 93,8 %, no del 100 %. Las siguientes limitaciones son la calidad de la imagen de prueba y la calidad de las imágenes de entrenamiento. La mayor amenaza para este proceso sería el etiquetado incorrecto de las imágenes de entrenamiento, lo que generaría un sesgo falso. Si algunas imágenes de entrenamiento estuvieran mal etiquetadas, miles de pruebas podrían clasificarse erróneamente.

5. Referencias

[1] S. Khan, A. Rahman, T. Debnath, R. Karim, M. Nasir, S. Band, A. Mosavi, and I. Dehzangi, “Accurate brain tumor detection using deep convolutional neural network,” sciencedirect.com, 2022. https://www.sciencedirect.com/science/article/pii/S2001037022003737#s0070 [accedido, 1 de mayo, 2025].

[2] R. Herzog, D. Elgort, A. Flanders, and P. Moley, “Variability in diagnostic error rates of 10 MRI centers performing lumbar spine MRI examinations on the same patient within a 3-week period” pubmed.ncbi.nlm.nih.gov, 2016, https://pubmed.ncbi.nlm.nih.gov/27867079/ [accedido 1 de Mayo, 2025]

[3] “What are the advantages and disadvantages of using convolutional neural networks for image recognition? ,” linkedin, ttps://www.linkedin.com/advice/0/what-advantages-disadvantages-using-convolutional [accedido 30 de abril 2025].